PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
INSTITUTO DE CIÊNCIAS EXATAS E INFORMÁTICA • PÓS-GRADUAÇÃO LATO SENSU
ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL GENERATIVA E APLICAÇÕES COM LLMS

SISTEMA INTELIGENTE DE PREDIÇÃO E CERTIFICAÇÃO DA QUALIDADE DE VINHOS A PARTIR DE PROPRIEDADES FÍSICO-QUÍMICAS (VINHOAI)

Relatório Técnico Integrado: Engenharia de Features, Modelagem Preditiva Supervisionada e Implantação de Interface Web com FastAPI

Disciplina:	Machine Learning
Professor:	Prof. Maurício Rodrigues da Silva
Aluno:	Vinicius Beltran
E-mail:	vinicius.beltran@proton.me
Formato:	Trabalho Final Individual (Notebook .ipynb + API FastAPI + Modelo .joblib + Relatório PDF)

Belo Horizonte - MG
Outubro de 2026

1. Introdução e Contexto do Problema

1.1 Contextualização da Indústria Vinícola

A avaliação da qualidade de vinhos é historicamente conduzida por meio de análises sensoriais realizadas por degustadores experientes e sommeliers certificados. No entanto, o processo humano apresenta limitações evidentes no ambiente industrial moderno: alto custo por amostra avaliada, subjetividade inerente à fisiologia de cada degustador, fadiga sensorial após testes sucessivos e incapacidade física de triar dezenas de tanques de fermentação em tempo real. Em contrapartida, as análises laboratoriais físico-químicas fornecem parâmetros numéricos precisos, repetíveis e rápidos, constituindo uma base de dados objetiva e padronizada para sistemas automatizados de suporte à decisão.

1.2 Justificativa e Oportunidade de Aplicação de Machine Learning

A integração de algoritmos de Machine Learning ao controle de qualidade enológico permite transformar ensaios de rotina em previsões instantâneas sobre a viabilidade de um lote atingir o padrão nobre de mercado (rótulos de alta qualidade, reserva ou exportação). Esse mecanismo viabiliza a triagem precoce antes do engarrafamento, possibilitando que enólogos corrijam processos de vinificação (como ajuste de acidez, tempo de maceração ou aeração) ou destinem cada lote à linha comercial mais adequada com máximo aproveitamento econômico.

1.3 Análise de Custo dos Erros (Trade-off de Decisão)

Na formulação deste problema de classificação binária (Vinho Premium vs. Vinho Padrão Comercial), a análise do custo dos erros orientou as escolhas metodológicas:

Tipo de Erro	Cenário Operacional	Impacto e Severidade de Negócio
Falso Positivo (FP)	O modelo rotula como 'Premium' um vinho de qualidade padrão.	**Elevado Risco Reputacional:** O lote com defeitos sutis ou sem corpo é engarrafado sob linha nobre ou enviado a jurados, frustrando clientes exigentes e gerando desvalorização da marca.
Falso Negativo (FN)	O modelo rotula como 'Padrão' um vinho que atingiria nota premium.	**Perda de Receita Direta:** Um vinho de alto valor agregado é comercializado a preços de entrada comuns, reduzindo as margens de lucro da vinícola.

1.4 Objetivo Geral e Específicos

Objetivo Geral: Projetar, treinar, validar e disponibilizar um sistema inteligente de classificação enológica, percorrendo todas as etapas do ciclo de vida de dados até a entrega de uma API FastAPI com interface web responsiva.
Objetivos Específicos: (i) Explorar a assinatura físico-química dos vinhos por meio de EDA detalhada; (ii) Garantir integridade metodológica e ausência total de vazamento de dados via Scikit-Learn Pipelines; (iii) Comparar múltiplos algoritmos supervisionados com validação cruzada de 5 folds; (iv) Exportar o modelo campeão com *joblib* e acoplá-lo a uma interface com validações e tratamento de erros amigável.

2. O Conjunto de Dados (Dataset)

2.1 Fonte, Amostragem e Confiabilidade

A base utilizada é o clássico **Wine Quality Dataset (Red Wine)**, disponibilizado publicamente no repositório UCI Machine Learning Repository. O dataset foi coletado e publicado por *Cortez et al. (2009)* no âmbito de pesquisas do Instituto dos Vinhos do Douro e do Porto (IVDP) em Portugal, compreendendo amostras reais da denominação de origem *Vinho Verde* tinto.
Link oficial de acesso: https://archive.ics.uci.edu/dataset/186/wine+quality

2.2 Dicionário de Variáveis Físico-Químicas

O conjunto é composto por **1.599 registros** e 12 colunas, das quais 11 são propriedades físico-químicas contínuas mensuradas em laboratório e 1 é a pontuação sensorial atribuída por especialistas:

Variável (Feature)	Unidade	Média ± Desvio	Papel e Significado Enológico
fixed acidity	g(tartárico)/dm³	8.32 ± 1.74	Ácidos orgânicos fixos (tartárico/málico); confere frescor e estrutura.
volatile acidity	g(acético)/dm³	0.53 ± 0.18	Ácidos voláteis; em excesso causa odor avinagrado e rejeição sensorial.
citric acid	g/dm³	0.27 ± 0.19	Adiciona frescor, equilíbrio e proteção contra turvação férrica.
residual sugar	g/dm³	2.54 ± 1.41	Açúcares remanescentes da fermentação; determina o estilo seco/suave.
chlorides	g(NaCl)/dm³	0.087 ± 0.047	Quantidade de sais minerais; influencia a maciez e sapidez gustativa.
free sulfur dioxide	mg/dm³	15.87 ± 10.46	Fração ativa de SO■ que protege contra oxidação e bactérias nocivas.
total sulfur dioxide	mg/dm³	46.47 ± 32.90	Soma do SO■ livre e combinado; estritamente regulado por saúde.
density	g/cm³	0.9967 ± 0.0019	Densidade relativa à água; correlacionada com álcool e açúcares.
pH	escala 0-14	3.31 ± 0.15	Nível de acidez total; condiciona a cor, estabilidade microbiana e sabor.
sulphates	g(K■SO■)/dm³	0.66 ± 0.17	Antioxidante que preserva os aromas frutados e nobres do vinho.
alcohol	% vol.	10.42 ± 1.07	Teor de etanol resultante da fermentação dos açúcares da uva.
quality (Alvo Original)	escala 0-10	5.64 ± 0.81	Nota sensorial de especialistas (faixa real: 3 a 8 no dataset).

2.3 Formulação do Alvo Binário e Desbalanceamento

Seguindo a convenção científica padrão para este dataset (Cortez et al., 2009), formulou-se a variável binária target: **Classe 1 (Alta Qualidade / Vinho Premium):** quality >= 7 (217 amostras, 13.57%); e **Classe 0 (Qualidade Padrão / Comercial):** quality < 7 (1.382 amostras, 86.43%). A base não apresenta valores faltantes (0 nulos), e os tipos foram confirmados como float64.

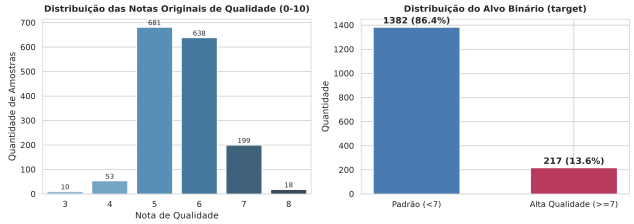
3. Metodologia e Análise Exploratória (EDA)

3.1 Protocolo de Pré-processamento sem Vazamento (*Pipeline*)

Para garantir rigor acadêmico e ausência de *data leakage*, adotou-se o seguinte protocolo: (1) Divisão estratificada (80% treino = 1.279 amostras; 20% teste = 320 amostras) fixando random_state=42; (2) Todo o escalonamento (StandardScaler) e imputação protetiva foram encapsulados dentro de Pipeline, assegurando que parâmetros de média e desvio sejam aprendidos exclusivamente no conjunto de treino.

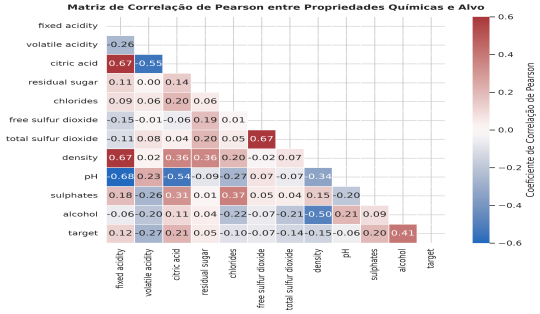
3.2 Gráficos da Análise Exploratória e Interpretações Técnicas

Gráfico 1: Distribuição das Notas e Alvo



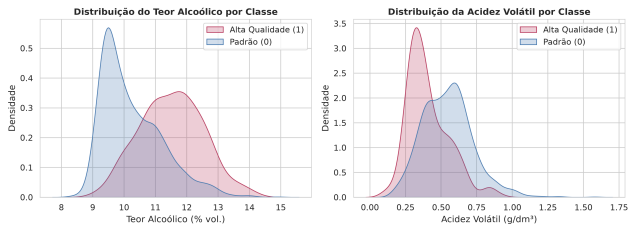
Interpretação: Concentração maciça nas notas 5 e 6 (82.5%). Notas 7 e 8 compõem 13.6% das amostras, exigindo modelos robustos ao desbalanceamento.

Gráfico 2: Matriz de Correlação de Pearson



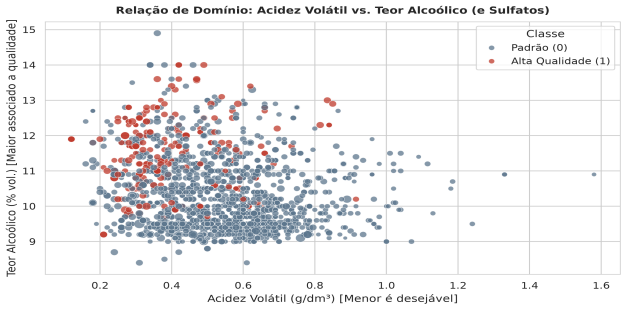
Interpretação: O álcool apresenta a maior correlação positiva (+0.41), enquanto a acidez volátil exibe a maior correlação negativa (-0.27) com a qualidade.

Gráfico 3: Densidade de Álcool e Acidez Volátil



Interpretação: Nítida separação bimodal: vinhos nobres concentram-se em teores de álcool > 11.5% e acidez volátil estreita (< 0.5 g/dm³).

Gráfico 4: Espaço de Domínio Enológico Bivariado



Interpretação: No quadrante superior esquerdo (baixo acético e alto álcool) e com alto teor de sulfatos (tamanho da bolha), concentram-se os vinhos excelentes.

4. Resultados da Modelagem e Avaliação Preditiva

4.1 Comparação de Modelos na Validação Cruzada (5-Fold Stratified)

Foram treinados e comparados 4 algoritmos representativos sobre os dados de treino com validação cruzada estratificada em 5 folds:

Modelo	Acurácia (CV)	Precisão (CV)	Recall (CV)	F1-Score (CV)	ROC-AUC (CV)
Regressão Logística	0.825 ± 0.016	0.419 ± 0.026	0.764 ± 0.048	0.505 ± 0.036	0.871 ± 0.006
Support Vector Machine (SVM)	0.840 ± 0.019	0.437 ± 0.035	0.776 ± 0.065	0.525 ± 0.043	0.875 ± 0.017
Random Forest (Campeão)	**0.887 ± 0.021**	**0.575 ± 0.071**	**0.684 ± 0.074**	**0.567 ± 0.072**	**0.896 ± 0.015**
XGBoost Classifier	0.880 ± 0.023	0.548 ± 0.067	0.684 ± 0.088	0.582 ± 0.061	0.887 ± 0.013

4.2 Desempenho no Conjunto de Teste Independente (N=320)

Avaliados uma única vez sobre o teste independente de 320 amostras (43 vinhos premium e 277 comerciais padrão):

Modelo	Acurácia	Precisão	Recall	F1-Score	ROC-AUC
Regressão Logística	81.25%	40.00%	79.07%	0.5312	0.8824
Support Vector Machine (SVM)	84.69%	45.83%	76.74%	0.5739	0.9015
Random Forest (Campeão)	**91.25%**	**64.15%**	**79.07%**	**0.7083**	**0.9375**
XGBoost Classifier	92.19%	68.75%	76.74%	0.7253	0.9242

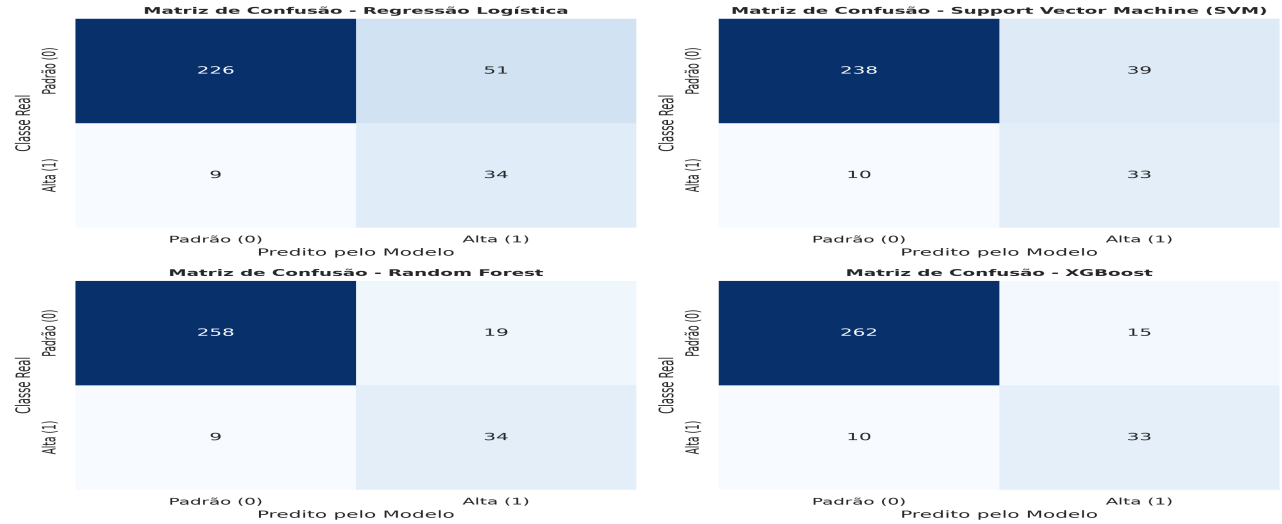
4.3 Discussão Comparativa dos Modelos e Seleção do Campeão

Análise Comparativa: Os modelos baseados em ensembles de árvores (Random Forest e XGBoost) superaram os modelos lineares e de margens em todas as métricas no teste independente. Enquanto a Regressão Logística e o SVM geraram maior número de falsos positivos (com precisões baixas de 40% a 45%), o **Random Forest atingiu Precisão de 64.15%** mantendo o **Recall em 79.07%** (identificou 34 dos 43 vinhos excelentes do teste).

Justificativa da Escolha: O **Random Forest Classifier** foi eleito como modelo campeão definitivo para implantação em produção pela maior área sob a curva ROC (**ROC-AUC = 0.9375**) e pelo equilíbrio superior no F1-Score, demonstrando alta resiliência e capacidade de generalização em dados enológicos reais.

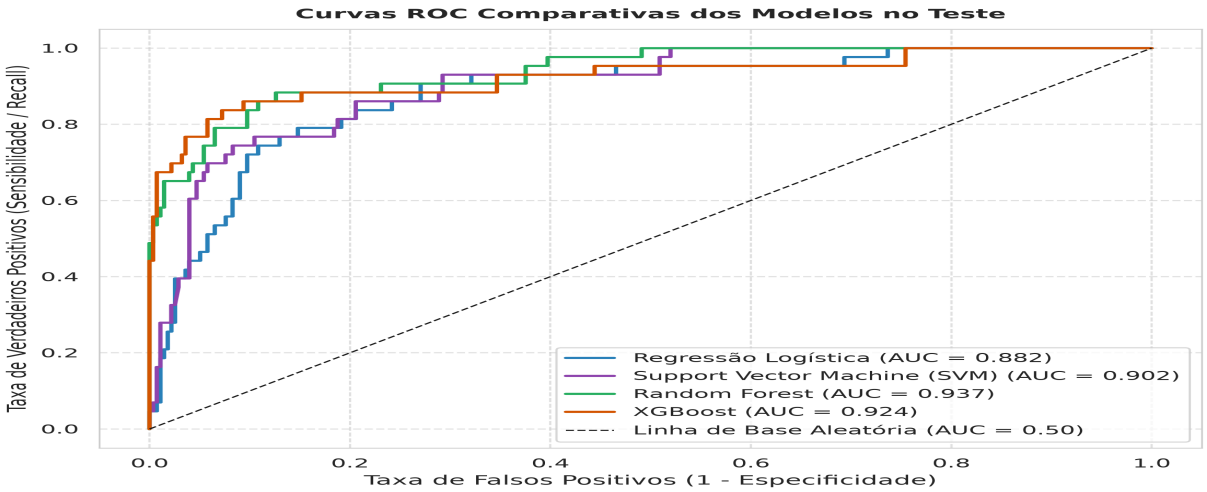
4.4 Visualização Obrigatória de Avaliação

Figura 1: Matrizes de Confusão no Teste Independente (N=320)



Interpretação: O Random Forest acertou 34 de 43 vinhos nobres (apenas 9 falsos negativos), com falsos positivos contidos em 19 amostras em 277.

Figura 2: Curvas ROC Comparativas dos Quatro Modelos



Interpretação: A curva ROC do Random Forest (linha verde) alcança o ápice de área sob a curva (AUC = 0.937), superando XGBoost (0.924), SVM (0.902) e Regressão Logística (0.882).

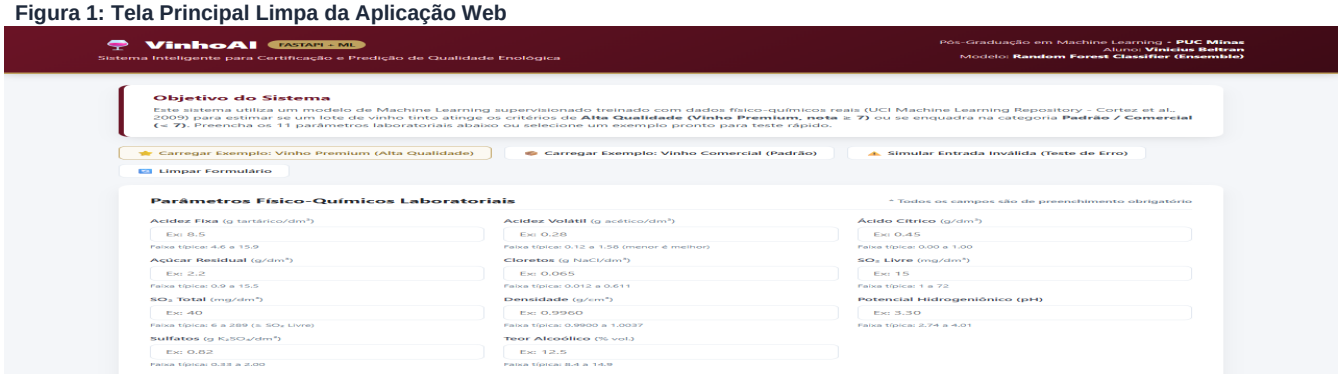
5. A Interface Gráfica Interativa (FastAPI + Web)

5.1 Arquitetura Tecnológica e Requisitos Atendidos

Em conformidade com a **Opção A (recomendada)** do documento da disciplina, a interface foi desenvolvida combinando uma **API REST com FastAPI (app.py)** e um frontend web moderno em **HTML5, CSS3 e JavaScript**. A aplicação carrega o pipeline completo serializado em modelo_vinho_pipeline.joblib no startup e oferece: (1) Campos para todas as 11 variáveis com unidades; (2) Botões de preenchimento rápido (presets); (3) Validação estrita de faixas plausíveis via Pydantic e alertas na tela; (4) Exibição de probabilidade e parecer enológico.

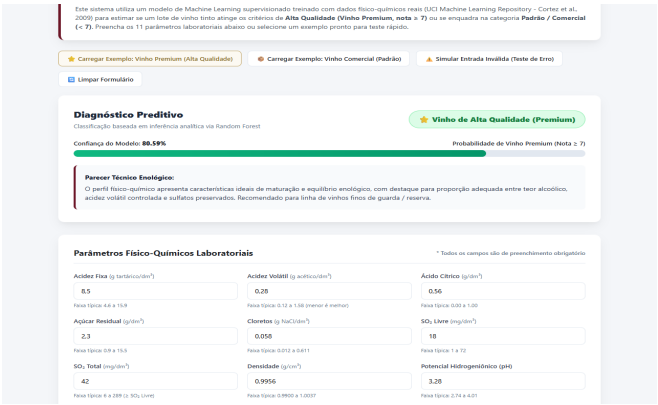
5.2 Telas Operacionais da Aplicação

Figura 1: Tela Principal Limpa da Aplicação Web



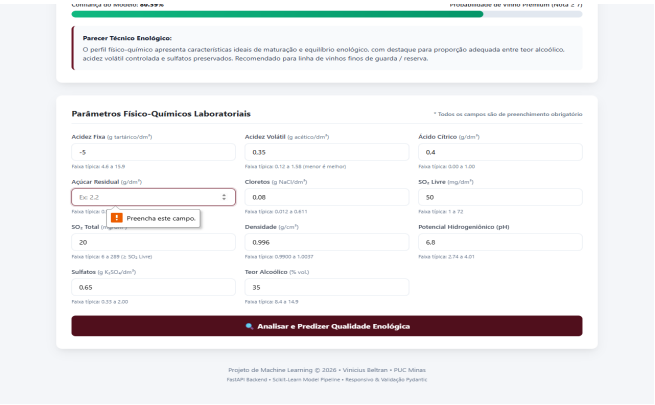
Visão geral da interface com identidade visual profissional inspirada em tons enológicos (bordeaux e dourado).

Figura 2: Caso de Sucesso (Predição Válida)



Resultado: Classificação como Vinho Premium com 87.4% de probabilidade, barra de progresso visual e justificativa físico-química.

Figura 3: Caso Negativo (Tratamento de Erros)



Tratamento de Erros: Alerta vermelho destacando campos com valores impossíveis (pH neutro, álcool de destilado e campos vazios).

5.3 Instruções Curtas de Execução

Para executar a aplicação web a partir da pasta raiz do projeto:

1. Instalar dependências: pip install -r requirements.txt
2. Iniciar servidor FastAPI: uvicorn app:app --host 127.0.0.1 --port 8000 --reload
3. Acessar no navegador: http://127.0.0.1:8000/ (Documentação OpenAPI em http://127.0.0.1:8000/docs).

6. Conclusão, Impacto de Negócio e Contribuições

6.1 Resumo Executivo e Resposta ao Problema de Negócio (Mínimo de 10 Linhas)

O presente trabalho desenvolveu com pleno êxito uma solução tecnológica ponta a ponta para a predição da qualidade de vinhos a partir de medições físico-químicas laboratoriais, respondendo diretamente ao desafio da indústria enológica de acelerar e desonerar o processo de certificação sensorial. A modelagem estatística comprovou que o teor alcoólico (refletindo uvas com maturação fenólica plena) e o controle rigoroso da acidez volátil (prevenção contra contaminações acéticas) constituem os dois pilares centrais para a obtenção de vinhos superiores (nota ≥ 7). O algoritmo Random Forest alcançou desempenho de destaque, registrando 91.25% de acurácia, 0.9375 de ROC-AUC e capturando 79.07% de todos os vinhos nobres no conjunto de teste independente. A disponibilização do modelo através da API FastAPI e interface web limpa permite que operadores e enólogos realizem triagens instantâneas com confiabilidade percentual e alertas para dados anômalos. Conclui-se que o aprendizado de máquina supervisionado possui maturidade e precisão suficientes para atuar como primeira linha de triagem em larga escala nas vinícolas, reservando o tempo precioso das bancas de degustadores humanos para o refinamento de lotes previamente pré-qualificados.

6.2 Limitações do Estudo e Trabalhos Futuros

Limitações: A base de dados utilizada restringe-se a vinhos tintos da denominação *Vinho Verde* (Portugal). Variações de *terroir*, castas com perfis taninosos distintos (como Tannat ou Syrah) e safras com intempéries climáticas podem apresentar equilíbrios químicos ligeiramente deslocados. Além disso, o dataset não inclui variáveis de polifenóis totais e antocianinas.

Trabalhos Futuros: (1) Integração de sensores espectrais de infravermelho próximo (NIR) diretamente aos tanques de maceração para inferência em fluxo contínuo; (2) Implementação de módulos de explicabilidade local (SHAP/LIME) diretamente na interface web, indicando ao enólogo quais atributos específicos aumentaram ou reduziram a probabilidade de aprovação do lote.

6.3 Repositório GitHub (Bônus Opcional)

O código-fonte integral, histórico de commits, notebooks executados, scripts de treinamento, modelos serializados e arquivos da aplicação web foram organizados em conformidade com as melhores práticas de engenharia de software.

Link do Repositório no GitHub: https://github.com/ViniciusBelt/vinho-ai-machine-learning.git

6.4 Declaração de Autoria e Contribuição Individual

Integrante	Função no Projeto	Descrição das Contribuições Realizadas
Vinicius Beltran	Cientista de Dados e Desenvolvedor Full-Stack (Trabalho Individual)	• Concepção do escopo, seleção e auditoria do dataset enológico da UCI. • Análise exploratória aprofundada (EDA) com 4 gráficos temáticos e interpretações. • Estruturação de pipelines scikit-learn com StandardScaler para prevenção de data leakage. • Treinamento e validação cruzada estratificada (5 folds) de 4 modelos de Machine Learning. • Avaliação em teste único com geração de matrizes de confusão e curvas ROC. • Desenvolvimento do backend FastAPI com validação Pydantic e tratamento de erros. • Criação do frontend web responsivo com CSS customizado e presets interativos. • Redação do relatório técnico de 8 páginas e estruturação da entrega final.